

Projet 3 - Greffes d'organes

tasnim

2025-11-29

L'objectif de l'étude est de déterminer si le nombre de jours pendant lesquels un patient a survécu était influencé par l'organe affecté. Nous disposons d'un jeu de données (dataframe) présentant 2 types de variables: variable dépendante (survie mesurée en jours) et variable indépendante (organes avec estomac, côlon, ovaires, poumons et seins)

```
# Structure globale du dataframe
str(organ)
```

```
## 'data.frame': 64 obs. of 2 variables:
## $ Survival: int 124 42 25 45 412 51 1112 46 103 876 ...
## $ Organ : chr "Stomach" "Stomach" "Stomach" "Stomach" ...
```

1) Créer des récapitulatifs statistiques pour chaque organe (mean, median, quartiles...)

```
by(organ$Survival, organ$Organ, summary)
```

```
## organ$Organ: Breast
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    24     723    1166    1396    1692    3808
## -----
## organ$Organ: Bronchus
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  20.0    72.0   155.0   211.6   245.0   859.0
## -----
## organ$Organ: Colon
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  20.0   189.0   372.0   457.4   519.0  1843.0
## -----
## organ$Organ: Ovary
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   89.0   239.8   406.0   884.3  1039.5  2970.0
## -----
## organ$Organ: Stomach
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    25     46    124     286    396    1112
```

```
tab <- organ %>%
  group_by(Organ)%>%
  summarise(summary=list(summary(Survival)))%>%
```


```
tidyr::unnest_wider(summary)
knitr::kable(tab, caption = "Tableau récapitulatif de la survie pour chaque organe", digits =2)
```

Table 1: Tableau récapitulatif de la survie pour chaque organe

Organ	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
Breast	24	723.00	1166	1395.9091	1692.5	3808
Bronchus	20	72.00	155	211.5882	245.0	859
Colon	20	189.00	372	457.4118	519.0	1843
Ovary	89	239.75	406	884.3333	1039.5	2970
Stomach	25	46.00	124	286.0000	396.0	1112

2) Vérifier la présence de valeurs extrêmes avec des boxplots :

```
# Boxplots avec couleurs par organe :
boxplot(Survival~Organ,data = organ, col = c('red', 'orange','green','blue','purple' ),
main = "Survie par organe", ylab='Jours de survie', range=1)
```



```
outliers <- organ %>%
  group_by(Organ)%>%
  identify_outliers(Survival)
knitr::kable(outliers, caption = "Valeurs extrêmes", digits =2)
```

Table 2: Valeurs extrêmes

Organ	Survival	is.outlier	is.extreme
Breast	3808	TRUE	FALSE
Breast	3460	TRUE	FALSE
Bronchus	859	TRUE	TRUE
Colon	1843	TRUE	TRUE
Ovary	2970	TRUE	FALSE
Stomach	1112	TRUE	FALSE

Dans le dataframe organ, il y a la présence d'outliers. Certains patients ont survécu beaucoup plus longtemps (ou moins) que la majorité de leur groupe. Ces valeurs extrêmes vont à l'encontre de l'hypothèse de normalité nécessaire pour l'ANOVA. Il s'agit donc d'une distribution asymétrique des temps de survie. Besoin de transformer en $\log()$.

3) Vérifier la normalité et l'égalité des variances :

- Indépendance des observations :


Chaque sujet doit appartenir à un seul groupe. Il n'y a pas de relation entre les observations dans chaque groupe. Il n'est pas permis d'avoir des mesures répétées pour les mêmes participants.

- Normalité :


Les données de chaque groupe doivent être distribuées à peu près normalement.

```
qqnorm(organ$Survival,pch=19, main = 'Distribution anormale des organes');
qqline(organ$Survival)
```

Distribution anormale des organes



```
# Analyse des résidus ANOVA :  
model <- lm(Survival ~ Organ, data= organ)  
ggqqplot(residuals(model))
```



```
shap<- shapiro_test(organ$Survival)
print(shap)
```

```
## # A tibble: 1 x 3
##   variable      statistic p.value
##   <chr>         <dbl>    <dbl>
## 1 organ$Survival 0.662 7.20e-11
```

```
# Vérifier la normalité de chaque groupe séparément :
shapiro.test(organ$Survival[organ$Organ == 'Stomach'])
```

```
##
## Shapiro-Wilk normality test
##
## data: organ$Survival[organ$Organ == "Stomach"]
## W = 0.75473, p-value = 0.002075
```

```
shapiro.test(organ$Survival[organ$Organ == 'Breast'])
```

```
##
## Shapiro-Wilk normality test
##
## data: organ$Survival[organ$Organ == "Breast"]
## W = 0.86857, p-value = 0.07431
```

```
shapiro.test(organ$Survival[organ$Organ == 'Ovary'])
```

```
##  
## Shapiro-Wilk normality test  
##  
## data: organ$Survival[organ$Organ == "Ovary"]  
## W = 0.76688, p-value = 0.029
```

```
shapiro.test(organ$Survival[organ$Organ == 'Bronchus'])
```


```
##  
## Shapiro-Wilk normality test  
##  
## data: organ$Survival[organ$Organ == "Bronchus"]  
## W = 0.76596, p-value = 0.0007186
```

```
shapiro.test(organ$Survival[organ$Organ == 'Colon'])
```

```
##  
## Shapiro-Wilk normality test  
##  
## data: organ$Survival[organ$Organ == "Colon"]  
## W = 0.76056, p-value = 0.0006134
```

Seulement la p-value de 'Breast' est supérieure à 0.05. Pour les autres, on rejette H0 et la distribution n'est pas normale.

```
ggqqplot(organ, "Survival", facet.by="Organ", color='Organ')
```




Hypothèse nulle H_0 est rejetée : Les résidus ne suivent pas une loi normale. Si $p\text{-value} > 0.05$, on ne rejette pas H_0 , les résidus sont compatibles avec la normalité et l'ANOVA est utilisable. Dans le cas contraire, où, $p\text{-value} < 0.05$, on rejette H_0 , les résidus s'écartent significativement de la normalité et l'ANOVA est peu fiable (risque sur les p-values).

Ici, il semblerait que le test de Shapiro rejette H_0 (sauf pour 'Breast'), mais les ggqqplot semblent valider une normalité apparente.

Le test d'ANOVA semble difficile à effectuer actuellement.

- Homogénéité de la variance :

```
plot(model, 1)
```



Les points ne sont pas disposés de façon ‘nuagée’ homogène autour du 0. Il y a la présence de cônes qui sont les résidus de plus en plus dispersés quand la moyenne augmente. Les variances ne sont donc pas homogènes et on peut qualifier cela d’hétéroscédasticité.

4) Transformer les données ($\log(\text{Survival})$) et revérifier la normalité et l’égalité des variances :

```
organ$log_Survival <- log(organ$Survival)
```

- Valeurs extrêmes :


```
outliers_log <- organ %>%
  group_by(Organ) %>%
  identify_outliers(log_Survival)
knitr::kable(outliers_log, caption = "Valeurs extrêmes", digits =2)
```

Table 3: Valeurs extrêmes

Organ	Survival	log_Survival	is.outlier	is.extreme
Breast	24	3.18	TRUE	TRUE
Breast	40	3.69	TRUE	TRUE
Colon	20	3.00	TRUE	FALSE


- Normalité :


```
qqnorm(organ$log_Survival, main = 'Normal Q-Q Plot');
qqline(organ$log_Survival)
```



La normalité est validée.

```
# Analyse des résidus ANOVA :
modela<-lm(log_Survival ~Organ, data=organ)
ggqqplot(residuals(modela), main ="Analyse de normalité")
```



```
shapiro_test(organ$log_Survival)
```

```
## # A tibble: 1 x 3
##   variable      statistic p.value
##   <chr>         <dbl>   <dbl>
## 1 organ$log_Survival    0.983   0.540
```

Vérifier la normalité de chaque groupe séparément :

```
shapiro.test(organ$log_Survival[organ$Organ == 'Stomach'])
```

```
##
##  Shapiro-Wilk normality test
##
## data:  organ$log_Survival[organ$Organ == "Stomach"]
## W = 0.92837, p-value = 0.3245
```

```
shapiro.test(organ$log_Survival[organ$Organ == 'Breast'])
```

```
##
##  Shapiro-Wilk normality test
##
## data:  organ$log_Survival[organ$Organ == "Breast"]
## W = 0.802, p-value = 0.009995
```

```
shapiro.test(organ$log_Survival[organ$Organ == 'Ovary'])
```

```
##  
## Shapiro-Wilk normality test  
##  
## data: organ$log_Survival[organ$Organ == "Ovary"]  
## W = 0.983, p-value = 0.9655
```

```
shapiro.test(organ$log_Survival[organ$Organ == 'Bronchus'])
```


```
##  
## Shapiro-Wilk normality test  
##  
## data: organ$log_Survival[organ$Organ == "Bronchus"]  
## W = 0.98047, p-value = 0.9613
```

```
shapiro.test(organ$log_Survival[organ$Organ == 'Colon'])
```

```
##  
## Shapiro-Wilk normality test  
##  
## data: organ$log_Survival[organ$Organ == "Colon"]  
## W = 0.92636, p-value = 0.1891
```


Seulement la p-value de 'Breast' est inférieur à 0.05. Pour les autres, on conserve H0 et la distribution est normale.

```
ggqqplot(organ, "log_Survival", facet.by="Organ", color='Organ')
```



- Homogénéité de la variance :

```
plot(modela,1)
```



Les points sont dispersés de façon ‘nuagée’ homogène autour du 0. Il n’y a pas la formation de cônes. Les variances sont à peu près constantes. On peut parler d’homoscedasticité raisonnable.

5) Exécuter le test d’ANOVA suivi du test post-hoc de Tukey :

```
anova_log <- aov(log_Survival ~ Organ, data=organ)
summary(anova_log)
```

```
##           Df Sum Sq Mean Sq F value    Pr(>F)
## Organ      4  24.49   6.122    4.286 0.00412 **
## Residuals 59  84.27   1.428
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Ici, la p-value est inférieure à 0.05. On rejette H_0 , les différences sont significatives entre au moins 2 organes et les moyennes de survie ne sont toutes pas égales.

```
# Calculer la taille de l'effet :
effectsize::eta_squared(anova_log)
```

```
## For one-way between subjects designs, partial eta squared is equivalent
## to eta squared. Returning eta squared.
```

```
## # Effect Size for ANOVA
##
## Parameter | Eta2 |          95% CI
## -----
## Organ      | 0.23 | [0.05, 1.00]
##
## - One-sided CIs: upper bound fixed at [1.00].
```

23 % de la variabilité en survie est expliquée par l'organe. La taille de l'effet est très importante et suggère que le type d'organe explique une part de la variabilité observée en survie.

```
Tuk <- TukeyHSD(anova_log, conf.level = 0.95)
Tuk
```


```
## Tukey multiple comparisons of means
## 95% family-wise confidence level
##
## Fit: aov(formula = log_Survival ~ Organ, data = organ)
##
## $Organ
##              diff          lwr          upr          p adj
## Bronchus-Breast -1.60543320 -2.906741 -0.3041254 0.0083352
## Colon-Breast    -0.80948110 -2.110789  0.4918267 0.4119156
## Ovary-Breast    -0.40798703 -2.114754  1.2987803 0.9615409
## Stomach-Breast  -1.59068365 -2.968399 -0.2129685 0.0158132
## Colon-Bronchus   0.79595210 -0.357534  1.9494382 0.3072938
## Ovary-Bronchus   1.19744617 -0.399483  2.7943753 0.2296079
## Stomach-Bronchus 0.01474955 -1.224293  1.2537924 0.9999997
## Ovary-Colon      0.40149407 -1.195435  1.9984232 0.9540004
## Stomach-Colon    -0.78120255 -2.020245  0.4578403 0.3981146
## Stomach-Ovary    -1.18269662 -2.842480  0.4770864 0.2763506
```

Ici, la survie médiane des patients à qui a été greffé une bronche est significativement plus élevée que celle du groupe greffé d'un sein. De même, pour la survie médiane des patients greffés d'un estomac qui est significativement supérieure à celle des patients greffés d'un sein.

Cela est également visible sur le plot ci-dessous. Si l'intervalle croise zéro, cela n'est pas significatif.

```
par (mar=c(5,12,4,2))
plot(Tuk, las=1)
```

95% family-wise confidence level



D'après notre étude, le nombre de jours pendant lesquels un patient a survécu est bien influencé par l'organe affecté.